Subspace clustering de données hybrides avec application en océanographie

Sujet de stage proposé par F. Bouhadjera, V. Audigier et N. Niang

CNAM, Laboratoire CEDRIC, équipe MSDMA

2 rue Conté, 75003 Paris

Mots-clés : *Subspace clustering*, données fonctionnelles, données vectorielles, données hybrides, océanographie.

1 Contexte et problématique

Les données fonctionnelles représentent des phénomènes évoluant continûment en fonction du temps, de l'espace ou d'une autre variable d'intérêt. Avec le développement technologique, notamment celui des capteurs et des objets connectés, ces données sont de plus en plus présentes dans de nombreux domaines. La classification non supervisée (*clustering*) de données fonctionnelles constitue ainsi un enjeu important pour identifier des groupes d'observations présentant des structures de variabilité similaires. Une première stratégie, dite approche en deux étapes (*tandem*), consiste à réduire la dimension des données, puis à appliquer un algorithme de *clustering* sur les représentations obtenues. Toutefois, cette approche est souvent peu performante car la réduction de dimension est réalisée sans tenir compte de la structure en groupes, les deux étapes étant menées de manière indépendante. Les méthodes de classification en sous-espaces (*subspace clustering*) répondent à cette limite, elles partitionnent l'ensemble d'observations en groupes homogènes tout en identifiant, de façon simultanée, un sous-espaces de faible dimension dans lequel ces groupes sont représentés au mieux. Le sous-espace est alors choisi en fonction de la structure en groupes, ce qui conduit à de meilleures performances que les approches en deux étapes.

Dans de nombreuses applications, les données fonctionnelles s'accompagnent de variables supplémentaires de nature vectorielle, qui apportent une informations complémentaires pour caractériser les groupes. Nous parlons de données hybrides lorsque chaque observation est constitué à la fois d'une ou plusieurs courbes et d'un vecteur de variables quantitatives. La prise en compte simultanée de ces deux types de variables nécessite alors d'adapter les méthodes existantes de *clustering*. Ce stage vise à étendre les méthodes de *subspace clustering* au cas de données hybrides. L'application considérée concerne les données océanographiques utilisées en acoustique sous-marine. La grandeur d'intérêt est la célérité du son dans l'eau, représentée par des profils verticaux décrivant son évolution en fonction de la profondeur. Ces profils constituent les variables fonctionnelles de l'étude. Ils sont accompagnés de variables acoustiques supplémentaires de nature vectorielle (par exemple, la fréquence de coupure de chenaux, la distance de résurgence des ondes acoustiques, etc) qui devront être intégrées dans la procédure de *clustering*. L'objectif applicatif est de proposer une représentation réduite de ces données, permettant de caractériser les principaux groupes de profils acoustiques tout en préservant les structures essentielles de l'information initiale.

2 Objectifs

L'objectif principal du stage est de développer une extension des méthodes de *subspace clustering* au cas de données hybrides (fonctionnelles et vectorielles). Il se décline en quatre objectifs spécifiques :

- étudier les méthodes de *subspace clustering* pour données vectorielles (par exemple De Soete and Carroll [1994], Vichi and Kiers [2001]) et leurs extensions aux données fonctionnelles (par exemple Yamamoto [2012], Yamamoto and Terada [2014], Yamamoto and Hwang [2017]), puis les approches de *clustering* dédiées aux données hybrides, notamment les travaux récents de Daluwatumulle et al. [2026] ;
- formuler un critère d'optimisation pour le *subspace clustering* hybride intégrant un système de pondération des variables, le choix du nombre de groupes et celui de la dimension du sous-espace. Puis, développer un algorithme d'optimisation adapté à ce critère ;
- étudier la méthode proposée par simulation, en la comparant aux méthodes fonctionnelles existantes (FPCK et FFKM, par exemple) et à une approche en deux temps ;
- appliquer la méthode aux données océanographiques comprenant des profils de célérité du son et des variables acoustiques, et interpréter les groupes obtenus.

Des implémentations des méthodes de *subspace clustering* fonctionnelles sont disponibles dans le dépôt GitHub associé à Yamamoto and Hwang [2017] (https://github.com/michioyamamoto/fgrc) ainsi que le code fourni avec l'article Daluwatumulle et al. [2026]. Le stagiaire pourra s'en servir comme point de départ.

3 Calendrier prévisionnel

Le début du stage est prévu en janvier/février 2027, pour une durée d'environ 5 à 6 mois. Le travail se déroulera selon les étapes suivantes :

- Étape 1 (4 semaines) : étude bibliographique détaillée sur les méthodes de *subspace clustering*, de *clustering* de données fonctionnelles et de *clustering* de données hybrides.
- Étape 2 (6 semaines) : formulation du critère d'optimisation et développement de l'algorithme, avec implémentation.
- Étape 3 (6 semaines) : étude par simulation et comparaison avec les méthodes existantes.
- Étape 4 (2 semaines) : application aux données océanographiques et analyse des résultats.
- Étape 5 (2 semaines) : rédaction du rapport de stage et préparation de la soutenance.

4 Profil

Étudiant de Master 2 ou d'école d'ingénieurs dernière année dans le domaine des mathématiques appliquées, de la statistique ou de la science des données. Un bon niveau en analyse de données, en programmation, ainsi que des capacités à rédiger en Français et en Anglais sont attendus. Nécessité d'être présent sur le site.

5 Modalités de candidature

Les dossiers de candidatures devront être composés d'un cv détaillé, présentant l'adéquation du candidat par rapport au sujet, d'une lettre de motivation mettant en évidence les raisons de la candidature, ainsi que des relevés de notes associés au diplôme le plus élevé. Ces éléments devront être transmis par mail aux trois adresses suivantes : feriel.bouhadjera@lecnam.net ; vincent.audigier@cnam.fr ; ndeye.niang2@lecnam.net.

Références

Geert De Soete and J Douglas Carroll. K-means clustering in a low-dimensional euclidean space. In *New approaches in classification and data analysis*, pages 212–219. Springer, 1994.

Maurizio Vichi and Henk A.L. Kiers. Factorial k-means analysis for two-way data. *Computational Statistics Data Analysis*, 37(1) :49–64, 2001. ISSN 0167-9473. doi : https://doi.org/10.1016/S0167-9473(00)00064-5. URL https://www.sciencedirect.com/science/article/pii/S0167947300000645.

Michio Yamamoto. Clustering of functional data in a low-dimensional subspace. *Advances in Data Analysis and Classification*, 6(3) :219–247, 2012.

Michio Yamamoto and Yoshikazu Terada. Functional factorial k-means analysis. *Computational statistics & data analysis*, 79 : 133–148, 2014.

Michio Yamamoto and Heungsun Hwang. Dimension-reduced clustering of functional data via subspace separation. *Journal of Classification*, 34(2) :294–326, 2017.

Sekha D Daluwatumulle, Jeong Hoon Jang, Ying Cui, and Amita K Manatunga. Clustering hybrid functional and vector data. *Biometrical Journal*, 68(5) :e70184, 2026.